




信源编码的统计基础

通信原理：从概率模型到压缩极限

fanzuituanhuo

July 10, 2026

dyed in indigo, madder & weld; ruled in iron-gall. woven on LOOM.

总览地图

□□□□ 先抓住一条主线：信源编码先建模不确定性，再讨论在什么失真约束下能压到多低。

本页笔记的 spine 是：先建立信源统计模型，再选择失真约束，最后用信息度量给出可达到的压缩极限。单符号、序列、连续和有记忆信源给出“要编码的对象”；熵、条件熵、联合熵和互信息给出“能压缩到哪里”的语言。后面的无失真编码、限失真编码和变换编码都会沿着这条线展开。

一眼对照

对象	符号	统计描述
离散单符号信源	$X, \mathcal{X} = \{x_1, x_2, \dots, x_n\}$	用概率质量函数 $p(x_i)$ 描述每个符号出现的概率。
连续单符号信源	$X \in (a, b)$	用概率密度函数 $p(x)$ 描述取值附近的概率强度（本章不展开）。
离散消息序列信源	X^L	用 L 维联合分布 $p(x_1, x_2, \dots, x_L)$ 描述整段序列。
无记忆序列信源	$X_1, \dots, X_L$ 相互独立	联合概率可以分解为各符号概率的乘积。
信息熵	$H(X)$	度量一个信源平均不确定性，等于自信息量的数学期望。
条件熵与联合熵	$H(Y X), H(X, Y)$	描述已知一个信源后另一个信源的剩余不确定性，以及两个信源整体的不确定性。
互信息	$I(X; Y)$	描述观察 Y 后关于 X 的不确定性减少量。

后续路线

编码问题	核心量	本章前置知识的作用
无失真离散信源编码	$H(X)$	熵给出平均码长的理论下界，编码要尽量逼近这个下界。
限失真信源编码	$R(D)$	在允许平均失真 D 时，用率失真函数描述最小所需码率。
连续信源限失真编码	$R(D), d(x, \hat{x})$	连续取值需要指定失真度量和重构变量 $\hat{X}$ 。
矢量量化	码本 $\{y_i\}, D$	对多个样值联合量化，利用样值间相关性，优于标量量化。
有记忆信源编码	相关性、变换	先削弱样本间相关性，再对近似独立的分量编码，例如 transform coding。

1 通信系统与信源编码

□□□□ 这部分回答：为什么一上来就要研究信源的统计特性。

通信的起点是信源，它产生待传输的信息。信道只是承载信号的通道；真正决定编码能否有效、系统能否可靠的，是信源和信道各自的统计特性。

通信技术的两个性能维度

Trigger. 当题目问“通信系统为什么要统计建模”时，先分清两个目标。

目标	依赖的统计特性
有效性	主要取决于信源统计特性。信源越有冗余，越有压缩空间。
可靠性	主要取决于信道统计特性。噪声、干扰和差错概率决定抗干扰设计。

Definition 1.1 (信源). 信源是产生消息或信息的对象。它的输出通常不是确定值，而是具有 随机性 的随机对象。

Definition 1.2 (信道). 信道是传递信号经过的通道。它会影响传输的可靠性，因此常用信道的 统计特性 来描述噪声和差错。

Definition 1.3 (信源编码). 信源编码是在分析信源统计特性的基础上，用尽可能少的码率表示信源输出。无失真编码要求接收端能够完全恢复原消息；限失真编码允许在给定失真约束内恢复 近似消息。

Your turn. 把“有效性”和“可靠性”各自对应的对象填出来：

有效性 $\leftrightarrow$ 信源，可靠性 $\leftrightarrow$ 信道。

? 信源编码为什么首先要研究信源统计特性?

■ 2 信源分类与单符号信源

□□□□ 先看一次输出一个随机符号的信源，这是后面序列信源的基本积木。

信源可以按输出的对象来分：如果每次输出一个符号，叫单符号信源；如果连续输出一串符号，叫消息序列信源。也可以按取值集合分为离散信源和连续信源。

分类地图

分类角度	常见类型
按取值集合	离散信源，也可称数字信源；连续信源，也可称模拟信源。
按输出结构	单符号信源；消息序列信源，也就是随机过程形式的信源。

Definition 2.1 (离散单符号信源). 设离散单符号信源为随机变量 X , 其取值集合为

$$\mathcal{X} = \{x_1, x_2, \dots, x_n\}.$$

若每个符号 x_i 出现的概率为 $p(x_i)$, 则该信源的统计描述为

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_n \\ p(x_1) & p(x_2) & \cdots & p(x_n) \end{pmatrix},$$

其中

$$0 \leq p(x_i) \leq 1, \quad \sum_{i=1}^n p(x_i) = \underline{1}.$$

Definition 2.2 (连续单符号信源). 若信源输出 X 是连续随机变量, 例如 $X \in (a, b)$, 则通常用概率密度函数 $p(x)$ 描述。这里的 $p(x)$ 不是某一点的概率; 当 dx 很小时,

$$p(x) dx \approx P\{x \leq X < x + dx\}.$$

更一般地,

$$P\{\alpha \leq X \leq \beta\} = \int_{\alpha}^{\beta} p(x) dx.$$

也就是说, $p(x)$ 描述的是单位长度小区间中的 概率密度。

Remark 2.3. 离散情形用“概率质量”看每个符号, 连续情形用“概率密度”看区间附近。二者的共同点是: 都在回答信源输出落在某些取值上的可能性。本章聚焦离散信源; 连续信源及其微分熵将在后续课程中展开。

Your turn. 判断下面两个对象分别属于哪类信源:

二进制符号 $\{0, 1\}$: 离散信源, 连续取值 $X \in (a, b)$: 连续信源.

? 为什么连续信源中 $p(x)$ 通常叫概率密度而不是概率?

3 离散消息序列信源的统计描述

□□□□ 序列信源的关键变化: 输出不再是一个符号, 而是一整段符号向量。

消息序列信源关心的不是单个输出符号, 而是一段长度为 L 的符号序列。因此统计描述从一维概率分布升级为 L 维联合概率分布。

从符号集合到序列集合

设单个符号的取值集合为 $\mathcal{X}$ ，则长度为 L 的序列取值集合可写成

$$\mathcal{X}^L = \mathcal{X} \times \mathcal{X} \times \cdots \times \mathcal{X},$$

一次输出的消息序列为

$$X^L = (X_1, X_2, \cdots, X_L),$$

它是一个 L 维随机向量。某个具体序列可写为

$$x^L = (x_1, x_2, \cdots, x_L).$$

Definition 3.1 (L 维联合分布). 离散消息序列信源的统计特性由联合概率

$$p(x^L) = p(x_1, x_2, \cdots, x_L)$$

描述。一般地，它可以按条件概率链式分解为

$$p(x_1, x_2, \cdots, x_L) = p(x_1)p(x_2|x_1) \cdots p(x_L|x_1, x_2, \cdots, x_{L-1}).$$

这个式子说明：序列中后一个符号的概率可能依赖于 前面已经出现的符号。

Proposition 3.2 (序列取值个数). 若单符号信源有 n 个可能取值，则长度为 L 的离散消息序列共有

$$n^L$$

个可能序列。

Example 3.3. 若单符号集合是 $\{0, 1\}$ ，长度 $L = 3$ ，则全部序列为

000, 001, 010, 011, 100, 101, 110, 111.

这里共有 $2^3 = 8$ 个可能序列。

Your turn. 若四进制符号集合为 $\{0, 1, 2, 3\}$ ，序列长度 $L = 2$ ，可能序列数为

16 .

4 无记忆信源与等概二进制例子

? 为什么序列信源的概率模型一般要用联合分布，而不是只写每个符号自己的概率？

□□□□ 无记忆是最常见的简化：过去的符号不影响现在的符号。

真实序列信源可能有记忆，比如自然语言中前后字符相关。无记忆信源是一个重要特例：序列中各符号统计独立，所以联合分布可以直接分解成乘积。

Definition 4.1 (无记忆离散信源). 若序列中的各个符号相互统计独立，则称该序列信源为无记忆信源。此时

$$p(x_1, x_2, \dots, x_L) = \prod_{\ell=1}^L p(x_\ell).$$

它的核心条件是序列中前后符号之间没有 统计依赖。

Remark 4.2. 有记忆信源的相关性比较复杂，不能简单把联合概率写成各项乘积。例如某些文字、语音或图像信源，当前符号往往受前面符号影响。后面的有记忆信源编码会围绕一个目标展开：先解除或削弱相关性，再分别编码近似独立的分量。

Example 4.3 (三位等概二进制序列). 设单个符号 0 和 1 等概出现：

$$p(0) = p(1) = \frac{1}{2}.$$

当 $L = 3$ 时，可能序列共有 $2^3 = 8$ 个。若信源无记忆，则每个具体序列的概率为

$$p(x_1, x_2, x_3) = p(x_1)p(x_2)p(x_3) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}.$$

Your turn. 仍设 $p(0) = p(1) = 1/2$ 。请写出序列 101 的概率计算：

$$p(101) = p(1)p(0)p(1) = \underline{\frac{1}{2}} \cdot \underline{\frac{1}{2}} \cdot \underline{\frac{1}{2}} = \underline{\frac{1}{8}}.$$

Your turn. 如果 $p(0) = 0.7$, $p(1) = 0.3$ ，且仍为无记忆信源，请计算序列 001 的概率：

$$p(001) = \underline{0.7} \cdot \underline{0.7} \cdot \underline{0.3} = \underline{0.147}.$$

复习时可以按这个顺序默写：信源产生消息，信源编码利用统计冗余；单符号信源写 X 和 $p(x_i)$ ；序列信源写 X^L 和联合分布；无记忆时联合分布变成乘积。接下来要问的是：这些概率分布对应的“不确定性”到底有多大，以及这种不确定性如何限制压缩码率？

■ 5 信息熵：单符号离散信源的不确定性

□□□□ 熵不是某次收到的信息量，而是信源在统计意义上的平均不确定性。

前面我们已经把信源写成概率分布。信息熵 $H(X)$ 做的事，是把这个概率分布压缩成一个数：信源平均有多不确定，平均需要多少信息才能消除这种不确定性。

定义

Trigger. 当题目给出离散信源 X 、取值集合 $\mathcal{X} = \{x_1, \dots, x_n\}$ 及概率 $p(x_i)$ 时，用这个公式。

Definition 5.1 (信息熵). 设离散单符号信源 X 的概率分布为 $p(x_i)$ 。它的信息熵定义为

$$H(X) = \mathbb{E}[-\log p(X)] = - \sum_{i=1}^n p(x_i) \log p(x_i).$$

其中 $\mathbb{E}$ 表示数学期望。信息熵度量的是信源的 平均不确定性。

对数底与单位

对数底	单位	含义
2	bit	最常用，表示二进制信息单位。
e	nat	自然对数单位。
10	Hartley 或十进制单位	十进制对数单位。

Remark 5.2. 若某个符号概率为 0，约定 $0 \log 0 = 0$ 。直觉上，不可能发生的符号不会贡献平均不确定性。

二进制信源

Example 5.3 (二进制熵函数). 设二进制信源 $X \in \{0, 1\}$ ，且

$$p(0) = p, \quad p(1) = 1 - p.$$

若以 2 为对数底，则

$$H(X) = -p \log_2 p - (1 - p) \log_2 (1 - p) \triangleq h(p).$$

当 $p = \frac{1}{2}$ 时，两个符号等概，二进制熵达到最大值 1 bit。

n 进制信源的最大熵

Proposition 5.4 (等概分布最大熵). 若 n 进制离散信源 X 的取值集合为 $\mathcal{X} = \{x_1, \dots, x_n\}$, 则

$$H(X) \leq \log n.$$

等号成立当且仅当

$$p(x_1) = p(x_2) = \dots = p(x_n) = \frac{1}{n}.$$

Proof. 记 $p_i = p(x_i)$ 。若某些 $p_i = 0$, 这些项按约定 $0 \log 0 = 0$, 不会贡献熵。先考虑所有 $p_i > 0$ 的情形:

$$H(X) = - \sum_{i=1}^n p_i \log p_i = \sum_{i=1}^n p_i \log \frac{1}{p_i}.$$

因为 $\log t$ 是凹函数, 由 Jensen 不等式,

$$\sum_{i=1}^n p_i \log \frac{1}{p_i} \leq \log \left(\sum_{i=1}^n p_i \frac{1}{p_i} \right) = \log n.$$

因此 $H(X) \leq \log n$ 。

等号成立时, Jensen 不等式的等号条件要求

$$\frac{1}{p_1} = \frac{1}{p_2} = \dots = \frac{1}{p_n},$$

也就是

$$p_1 = p_2 = \dots = p_n.$$

再由 $\sum_{i=1}^n p_i = 1$, 得到

$$p_1 = p_2 = \dots = p_n = \frac{1}{n}.$$

反过来, 如果 $p_i = 1/n$, 则

$$H(X) = - \sum_{i=1}^n \frac{1}{n} \log \frac{1}{n} = \log n,$$

所以等号确实成立。

若只有 $k < n$ 个符号概率非零, 则同样的证明给出

$$H(X) \leq \log k < \log n,$$

因此在 n 个可能符号中达到最大熵时, 必须所有符号都以相同概率出现。 ■

Your turn. 复述最大熵证明的关键一步: 把

$$H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i}$$

看成对凹函数 $\log t$ 的加权平均, 因此由 Jensen 不等式得到

$$H(X) \leq \log \left(\sum_{i=1}^n p_i \frac{1}{p_i} \right) = \underline{\log n}.$$

信息量描述一次接收后不确定性减少了多少；信息熵描述接收前信源平均有多不确定。前者偏向一次事件，后者偏向整个信源的统计平均。对无失真离散信源编码，熵会成为平均码长的理论下界；对限失真编码，这个角色会由 $R(D)$ 接过去。

? 为什么等概信源的不确定性最大?

6 条件熵与联合熵

□□□□ 两个随机信源放在一起时，要区分“总不确定性”和“知道一个以后剩下多少”。

现在有两个离散信源 X 和 Y 。如果知道了 X ，对 Y 的不确定性通常会下降。这个剩余不确定性就是条件熵；把 (X, Y) 当成一个整体看，就是联合熵。

条件熵

Trigger. 当题目出现“已知 X 后 Y 还剩多少不确定性”时，用 $H(Y|X)$ 。

Definition 6.1 (条件熵). 设 X 的取值为 $x_1, \dots, x_n$ ， Y 的取值为 $y_1, \dots, y_m$ 。条件熵定义为

$$H(Y|X) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(y_j|x_i) = \mathbb{E}[-\log p(Y|X)].$$

它度量的是已知 X 后， Y 的 剩余不确定性。

Definition 6.2 (联合熵). 联合熵把二元随机向量 (X, Y) 看成一个整体：

$$H(X, Y) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(x_i, y_j).$$

它度量两个信源共同输出时的总体不确定性。

Proposition 6.3 (熵的链式法则). 联合熵可以分解为

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y).$$

Proof. 从联合概率的链式分解开始：

$$p(x_i, y_j) = p(x_i)p(y_j|x_i).$$

代入联合熵定义，并把乘积的对数拆成和：

$$- \sum_{i,j} p(x_i, y_j) \log [p(x_i)p(y_j|x_i)]$$

$$= - \sum_{i,j} p(x_i, y_j) \log p(x_i) - \sum_{i,j} p(x_i, y_j) \log p(y_j|x_i).$$

第一项中 $\sum_j p(x_i, y_j) = p(x_i)$ ，所以它等于 $H(X)$ ；第二项正是 $H(Y|X)$ 。因此

$$H(X, Y) = H(X) + H(Y|X).$$

同理也可以先写 $p(x_i, y_j) = p(y_j)p(x_i|y_j)$ ，得到

$$H(X, Y) = H(Y) + H(X|Y).$$



Your turn. 复述链式法则证明中最关键的一步：

$$\log [p(x_i)p(y_j|x_i)] = \underline{\log p(x_i) + \log p(y_j|x_i)}.$$

Shannon 不等式



Proposition 6.4 (条件不会增加不确定性).

$$H(Y|X) \leq H(Y), \quad H(X|Y) \leq H(X).$$

也就是说，知道另一个随机变量，只会减少或保持不确定性，不会增加平均不确定性。

Your turn. 若 X 和 Y 相互独立，则 Y 在已知 X 后没有变得更确定，因此

$$H(Y|X) = \underline{H(Y)}, \quad H(X, Y) = \underline{H(X)} + \underline{H(Y)}.$$

? 为什么 $H(X, Y)$ 既可以写成 $H(X) + H(Y|X)$ ，也可以写成 $H(Y) + H(X|Y)$?

7 互信息：不确定性的减少量

□□□□ 互信息把“收到一个信源后，对另一个信源多了解了多少”变成公式。

如果 X 是信源， Y 是信宿或接收端观察到的量，那么互信息 $I(X; Y)$ 衡量的是：观察 Y 以后，关于 X 的不确定性平均减少了多少。



Definition 7.1 (互信息). 互信息定义为

$$I(X;Y) = H(X) - H(X|Y).$$

等价地, 也可以写成

$$I(X;Y) = H(Y) - H(Y|X) = H(X) + H(Y) - H(X,Y).$$

因此, 互信息可以看成 X 与 Y 共享的那部分信息。



Proposition 7.2 (概率形式). 互信息也可以写成联合分布与边缘分布的比值:

$$I(X;Y) = \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)}.$$

等价地,

$$I(X;Y) = \mathbb{E} \left[\log \frac{p(X|Y)}{p(X)} \right] = \mathbb{E} \left[\log \frac{p(Y|X)}{p(Y)} \right].$$

Proof. 从

$$I(X;Y) = H(X) - H(X|Y)$$

出发。因为

$$p(x_i) = \sum_{j=1}^m p(x_i, y_j),$$

所以

$$\begin{aligned} H(X) &= - \sum_{i=1}^n p(x_i) \log p(x_i) \\ &= - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(x_i). \end{aligned}$$

另一方面,

$$H(X|Y) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(x_i|y_j).$$

两式相减, 得到

$$\begin{aligned} I(X;Y) &= \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) [\log p(x_i|y_j) - \log p(x_i)] \\ &= \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log \frac{p(x_i|y_j)}{p(x_i)}. \end{aligned}$$

再由条件概率

$$p(x_i|y_j) = \frac{p(x_i, y_j)}{p(y_j)}$$

可得

$$I(X;Y) = \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)}.$$

这也说明

$$I(X;Y) = \mathbb{E} \left[\log \frac{p(X|Y)}{p(X)} \right].$$

同理从 $I(X;Y) = H(Y) - H(Y|X)$ 出发, 可以得到

$$I(X;Y) = \mathbb{E} \left[\log \frac{p(Y|X)}{p(Y)} \right].$$



Your turn. 复述互信息等价式证明的关键动作:

$$H(X) = - \sum_i p(x_i) \log p(x_i) = - \sum_{i,j} \frac{p(x_i, y_j)}{p(x_i)} \log p(x_i),$$

所以 $H(X) - H(X|Y)$ 可以合并成同一个 (i, j) 双重求和。

性质

性质	含义
非负性	$I(X;Y) \geq 0$ 。平均来看, 观察不会让不确定性“负减少”。
对称性	$I(X;Y) = I(Y;X)$ 。Y 中关于 X 的信息量, 等于 X 中关于 Y 的信息量。
独立时为零	若 X 与 Y 独立, 则 $I(X;Y) = 0$ 。
完全确定时最大	若 Y 能完全确定 X, 则 $I(X;Y) = H(X)$ 。

Remark 7.3. 在固定信道转移概率 $p(y|x)$ 时, $I(X;Y)$ 是输入分布 $p(x)$ 的凹函数; 在固定输入分布 $p(x)$ 时, $I(X;Y)$ 是信道转移概率 $p(y|x)$ 的凸函数。这解释了两个后续优化问题: 固定信道 $p(y|x)$ 时, 最大化 $I(X;Y)$ 得信道容量; 固定失真约束时, 最小化 $I(X;\hat{X})$ 得率失真函数 $R(D)$ 。

Your turn. 用熵的图像直觉填空:

$$I(X;Y) = H(X) - H(X|Y)$$

表示观察 Y 以后, 关于 X 的不确定性减少了 $I(X;Y)$ 。

Your turn. 若 X 与 Y 独立, 则 $p(x_i, y_j) = p(x_i)p(y_j)$ 。代入概率形式可得

$$I(X;Y) = \sum_{i,j} p(x_i, y_j) \log \frac{1}{p(x_i)p(y_j)} = 0.$$

■ 8 无失真离散信源编码

□□□□ 这一节把前面的熵变成编码结论：若允许很长的分组，平均码率或平均码长可以逼近 $H(X)$ 。

无失真离散信源编码的核心问题是：把长度为 L 的信源序列 X^L 映射成码字，再由码字恢复出 $\hat{X}^L$ 。如果分组足够长，高概率序列集中在典型集里，于是只需要给典型序列分配码字，所需码字数量大约是 $2^{LH(X)}$ 。

编码模型

Trigger. 当题目出现 $\mathcal{X}^L$ 、码字集合 $\mathcal{U}^k$ 、编码映射 f 和译码映射 g 时，先画 $X^L \rightarrow U^k \rightarrow \hat{X}^L$ 这条链。

Definition 8.1 (分组信源编码). 设离散无记忆信源的长度 L 输出序列取值于 $\mathcal{X}^L$ ，码符号集合为 $\mathcal{U}$ ，每个码字长度为 k ，则码字集合为 $\mathcal{U}^k$ 。编码映射和译码映射分别为

$$f : \mathcal{X}^L \rightarrow \mathcal{U}^k, \quad g : \mathcal{U}^k \rightarrow \mathcal{X}^L.$$

整个过程可写为

$$X^L \xrightarrow{f} U^k \xrightarrow{g} \hat{X}^L,$$

其中 $\hat{X}^L$ 是译码恢复出来的 信源序列。

Remark 8.2. 若 k 为固定值，就是等长编码；若不同信源序列允许使用不同长度的码字，就是变长编码。本节先看分组等长编码的基本极限。

什么叫无失真

Definition 8.3 (严格无失真与渐近无失真). 严格无失真要求对每个输入序列都有

$$\hat{X}^L = X^L.$$

更常用的渐近无失真用错误概率描述：

$$P_e^{(L)} = P\{\hat{X}^L \neq X^L\}.$$

若当 $L \rightarrow \infty$ 时存在一族编码方案使

$$P_e^{(L)} \rightarrow 0,$$

则称可以实现渐近无失真编码。

Your turn. 把“严格无失真”和“渐近无失真”的差别填出来：

严格无失真： $\hat{X}^L = \underline{X^L}$, 渐近无失真： $P_e^{(L)} \rightarrow \underline{0}$.

码率

Definition 8.4 (编码速率). 若码符号集合 $\mathcal{U}$ 的大小为 M ，每个信源分组长度为 L ，码字长度为 k ，则编码速率定义为

$$R = \frac{k}{L} \log_2 M$$

bit/source symbol。它表示平均每个信源符号需要多少二进制位来表示。

Example 8.5. 若用二进制码字， $M = 2$ ，则

$$R = \frac{k}{L}.$$

若每个 $L = 4$ 的信源分组用 $k = 6$ 个二进制码元表示，则码率为

$$R = \frac{6}{4} = 1.5 \text{ bit/source symbol}.$$

Your turn. 若码符号集合大小为 $M = 4$ ，长度 $L = 5$ 的信源序列被编码成长度 $k = 6$ 的码字，则

$$R = \frac{k}{L} \log_2 M = \frac{6}{5} \log_2 4 = \underline{2.4}.$$

熵给出的可达极限

Theorem 8.6 (离散无记忆信源无失真编码定理). 设离散无记忆信源 X 的熵为 $H(X)$ 。对任意 $\epsilon > 0$ ，若编码速率满足

$$R = \frac{k}{L} \log_2 M > H(X) + \epsilon,$$

则当 L 足够大时，存在一族分组编码使错误概率

$$P_e^{(L)} < \delta$$

其中 $\delta > 0$ 可以任意小。反过来, 若

$$R < H(X),$$

则不可能实现渐近无失真编码。

Remark 8.7. 这个定理的严格证明要用典型序列和大数定律, 后面讲无失真信源编码定理时再完整证明。这里先保留结论和直觉: 高概率序列集中在典型集里, 典型集大小约为 $2^{LH(X)}$, 所以只要码字数能覆盖典型集, 错误概率就可以随 L 增大而变小。

典型序列的角色

Definition 8.8 (典型集). 对长度为 L 的信源序列, 把概率接近 $2^{-LH(X)}$ 的高概率序列放入典型集, 记作 $A_\epsilon^{(L)}$ 。当 L 足够大时,

$$P\{X^L \in A_\epsilon^{(L)}\} > 1 - \delta,$$

并且典型集大小大约满足

$$|A_\epsilon^{(L)}| \leq 2^{L(H(X)+\epsilon)}.$$

典型集解释了为什么“不是所有 n^L 个序列都同等重要”。虽然长度为 L 的序列总数是 n^L , 但实际概率质量几乎都集中在典型集里。编码器只需要重点照顾典型序列, 非典型序列造成的错误概率可以随着 L 增大而变小。

Your turn. 用典型集语言补完整个可达性思路:

$$P\{X^L \in A_\epsilon^{(L)}\} > 1 - \delta, \quad |A_\epsilon^{(L)}| \leq \underline{2^{L(H(X)+\epsilon)}}.$$

因此只要

$$M^k \geq |A_\epsilon^{(L)}|,$$

就有足够多码字覆盖典型序列, 也就是

$$R = \frac{k}{L} \log_2 M > \underline{H(X) + \epsilon}.$$

变长编码: 平均码长逼近熵

等长编码把每个长度为 L 的信源序列都塞进同样长的码字; 变长编码则让高概率序列用短码字, 低概率序列用长码字。它关心的不是固定码字长度 k , 而是平均码长 $\bar{K}$ 。

Definition 8.9 (平均码长). 设长度为 L 的信源序列 x^L 被编码成 m 元码字, 码长为 $K(x^L)$ 。平均码长定义为

$$\bar{K} = \sum_{x^L \in \mathcal{X}^L} p(x^L) K(x^L).$$

因此

$$\frac{\bar{K}}{L}$$

表示每个信源符号平均需要的 m 元码符号数。

Theorem 8.10 (变长编码定理). 设 X 为离散无记忆信源, 熵为 $H(X)$, 码符号集合大小为 m 。对长度为 L 的信源扩展进行唯一可译变长编码时, 任意唯一可译码都满足

$$\frac{\bar{K}}{L} \geq \frac{H(X)}{\log_2 m}.$$

另一方面, 存在一族 m 元即时码, 使

$$\frac{\bar{K}}{L} < \frac{H(X)}{\log_2 m} + \frac{1}{L}.$$

也就是说, 通过增大分组长度 L , 变长编码的每符号平均码长可以任意逼近熵下界。

Proof. 先看下界。任意唯一可译码的码长必须满足 Kraft 不等式, 因此它诱导的平均码长不可能低于信源扩展熵对应的 m 元码符号数:

$$\bar{K} \geq \frac{H(X^L)}{\log_2 m}.$$

由于信源无记忆,

$$H(X^L) = LH(X),$$

所以

$$\frac{\bar{K}}{L} \geq \frac{H(X)}{\log_2 m}.$$

再看可达性。对每个序列取 Shannon 码长

$$K(x^L) = \lceil -\log_m p(x^L) \rceil,$$

则

$$K(x^L) < -\log_m p(x^L) + 1.$$

对 x^L 求平均, 得到

$$\bar{K} < \frac{H(X^L)}{\log_2 m} + 1 = \frac{LH(X)}{\log_2 m} + 1.$$

两边除以 L , 即得

$$\frac{\bar{K}}{L} < \frac{H(X)}{\log_2 m} + \frac{1}{L}.$$

Your turn. 复述变长编码定理的关键夹逼：

$$\frac{H(X)}{\log_2 m} \leq \frac{\bar{K}}{L} < \frac{H(X)}{\log_2 m} + \frac{1}{L}.$$

当 $m = 2$ 时, $\log_2 m = 1$, 所以

$$H(X) \leq \frac{\bar{K}}{L} < H(X) + \frac{1}{L}.$$

■ **Definition 8.11** (编码效率). 把平均码长换算成 bit/source symbol:

$$R = \frac{\bar{K}}{L} \log_2 m.$$

编码效率定义为

$$\eta = \frac{H(X)}{R}.$$

当 R 越接近 $H(X)$, 编码效率越接近 1。

Your turn. 若采用二进制变长编码, 且分组长度 L 足够大, 使 $1/L < \epsilon$, 则定理给出

$$H(X) \leq \frac{\bar{K}}{L} < H(X) + \epsilon.$$

这说明二进制变长编码的平均码长可以逼近 $H(X)$ 。

? 为什么无失真离散信源编码的极限码率是 $H(X)$, 而不是 $\log n$?

■ 9 信息率失真函数 $R(D)$

□□□□ 这一节把互信息变成压缩极限：如果允许一点失真，最少需要保留多少信息？

有失真信源编码的核心问题是：在允许平均失真不超过 D 的条件下，寻找最优的试验信道 $p(\hat{x}|x)$ ，使得互信息 $I(X; \hat{X})$ 最小。这个最小值就是 $R(D)$ 。

从失真到允许失真

Trigger. 当题目不再要求 $\hat{X} = X$, 而是给出一个“平均误差不超过 D ”时, 就进入率失真框架。

在数字通信系统中，信源编码器与译码器的整体作用可以抽象为

$$X \xrightarrow{\text{编码/译码}} \hat{X}.$$

无失真编码要求 $\hat{X} = X$ ；有失真编码只要求二者之间的 平均失真 不超过某个允许值 D 。

Definition 9.1 (有失真编码的目标). 设信源 X 的字母表为 $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$ ，重构符号字母表为 $\hat{\mathcal{X}} = \{\hat{x}_1, \hat{x}_2, \dots, \hat{x}_m\}$ 。有失真信源编码的目标是：在

$$\mathbb{E}[d(X, \hat{X})] \leq \underline{D}$$

的条件下，使编码所需的信息率尽可能 小。

失真测度

Definition 9.2 (失真测度). 失真测度是一个非负函数

$$d : \mathcal{X} \times \hat{\mathcal{X}} \rightarrow \mathbb{R}^+,$$

其中 $d(x_i, \hat{x}_j)$ 表示把 x_i 重构为 $\hat{x}_j$ 所产生的失真程度。通常要求

$$d(x_i, \hat{x}_j) \geq 0, \quad d(x_i, x_i) = \underline{0}.$$

Example 9.3 (汉明失真). 对于离散信源，汉明失真只关心“对”或“错”：

$$d(x_i, \hat{x}_j) = \begin{cases} \underline{0}, & i = j, \\ \underline{1}, & i \neq j. \end{cases}$$

它的含义是：译码正确时失真为零，任何错误都计为同样大小的失真。

Example 9.4 (平方误差失真). 对于连续信源，常用的失真测度是

$$d(x, \hat{x}) = \underline{(x - \hat{x})^2}.$$

若 $X, \hat{X}$ 为向量，则可推广为欧氏距离平方 $\|\mathbf{x} - \hat{\mathbf{x}}\|^2$ 。

Your turn. 汉明失真和平方误差失真的侧重点有何不同？

汉明失真： d 只与 是否相同 有关。

平方误差失真： d 还与 误差大小 有关。

平均失真与允许失真度

设信源分布为 $p(x_i)$ ，试验信道为 $p(\hat{x}_j|x_i)$ ，则联合分布为

$$p(x_i, \hat{x}_j) = p(x_i)p(\hat{x}_j|x_i).$$

■ **Definition 9.5** (平均失真). 平均失真定义为

$$\bar{d} = \sum_{i=1}^n \sum_{j=1}^m p(x_i, \hat{x}_j) d(x_i, \hat{x}_j) = \mathbb{E} [d(X, \hat{X})].$$

■ **Definition 9.6** (允许失真度). 允许失真度 D 是平均失真的上界。一个试验信道可行，当且仅当

$$\bar{d} = \sum_{i=1}^n \sum_{j=1}^m p(x_i)p(\hat{x}_j|x_i)d(x_i, \hat{x}_j) \leq \underline{D}.$$

Your turn. 当 D 变小时，对重构质量的要求变 高，因此所需信息率通常会变 大；当 D 变大时，信息率可以变 小。

试验信道

■ **Definition 9.7** (试验信道). 在率失真理论中，信源编码与译码的整体过程抽象为条件概率分布 $p(\hat{x}_j|x_i)$ ，称为试验信道。它不是一个物理信道，而是描述编码/译码造成的随机映射。

所有满足平均失真约束的试验信道构成集合

$$\mathcal{P}_D = \{p(\hat{x}|x) : \mathbb{E} [d(X, \hat{X})] \leq D\}.$$

也就是说， $p(\hat{x}|x) \in \mathcal{P}_D$ 当且仅当

$$\sum_{i=1}^n \sum_{j=1}^m p(x_i)p(\hat{x}_j|x_i)d(x_i, \hat{x}_j) \leq D.$$

互信息作为“必须保留的信息量”

Proposition 9.8 (互信息的概率形式). 原信源 X 与重构信源 $\hat{X}$ 之间的互信息为

$$I(X; \hat{X}) = \sum_{i=1}^n \sum_{j=1}^m p(x_i) p(\hat{x}_j | x_i) \log \frac{p(\hat{x}_j | x_i)}{p(\hat{x}_j)},$$

其中

$$p(\hat{x}_j) = \sum_{i=1}^n p(x_i) p(\hat{x}_j | x_i).$$

互信息衡量：重构信源 $\hat{X}$ 中保留了多少关于原信源 X 的信息。在有失真压缩中， $I(X; \hat{X})$ 越小，意味着需要保留的信息越少，相应编码所需的信息率越 低。

信息率失真函数的定义

Definition 9.9 (信息率失真函数). 信息率失真函数定义为

$$R(D) = \min_{p(\hat{x}|x) \in \mathcal{P}_D} I(X; \hat{X}).$$

展开写即

$$R(D) = \min_{p(\hat{x}|x)} I(X; \hat{X})$$

满足约束

$$\sum_{i=1}^n \sum_{j=1}^m p(x_i) p(\hat{x}_j | x_i) d(x_i, \hat{x}_j) \leq D,$$

$$\sum_{j=1}^m p(\hat{x}_j | x_i) = 1, \quad i = 1, 2, \dots, n,$$

$$p(\hat{x}_j | x_i) \geq 0, \quad i = 1, 2, \dots, n, j = 1, 2, \dots, m.$$

$R(D)$ 的含义是：在平均失真不超过 D 的条件下，编码所需的最小信息率。它是一个 带约束的优化问题，优化变量是试验信道 $p(\hat{x}|x)$ ，目标函数是互信息。

率失真函数的基本性质

Proposition 9.10 (非负性). 由于互信息非负， $I(X; \hat{X}) \geq 0$ ，所以

$$R(D) \geq \underline{0}.$$

Proposition 9.11 (单调非增性). 若 $D_1 < D_2$ ，则

$$R(D_1) \underline{\geq} R(D_2).$$

直观含义：允许的失真越大，可选的试验信道越多，所需的最小信息率不会增加。

Proposition 9.12 (凸性). 率失真函数 $R(D)$ 是关于 D 的凸函数, 即对 $0 \leq \lambda \leq 1$, 有

$$R(\lambda D_1 + (1 - \lambda)D_2) \leq \lambda R(D_1) + (1 - \lambda)R(D_2).$$

Proof. 设两个最优试验信道分别达到 $(D_1, R(D_1))$ 和 $(D_2, R(D_2))$ 。引入辅助变量 $\theta \in \{1, 2\}$, 以概率 λ 取 $\theta = 1$ 、以概率 $1 - \lambda$ 取 $\theta = 2$ 。令 θ 与 X 独立, 并在 $\theta = k$ 时使用第 k 个试验信道 $p_k(\hat{x}|x)$ 。

这样得到的新条件分布为

$$p(\hat{x}|x) = \lambda p_1(\hat{x}|x) + (1 - \lambda)p_2(\hat{x}|x),$$

其平均失真为

$$\lambda D_1 + (1 - \lambda)D_2.$$

下面估计其互信息。由数据处理不等式,

$$I(X; \hat{X}) \leq I(X; \hat{X}, \theta).$$

而

$$I(X; \hat{X}, \theta) = I(X; \theta) + I(X; \hat{X}|\theta).$$

因为 θ 与 X 独立, $I(X; \theta) = 0$, 所以

$$I(X; \hat{X}|\theta) = \lambda I(X; \hat{X}_1) + (1 - \lambda)I(X; \hat{X}_2) = \lambda R(D_1) + (1 - \lambda)R(D_2).$$

因此

$$R(\lambda D_1 + (1 - \lambda)D_2) \leq \lambda R(D_1) + (1 - \lambda)R(D_2).$$

Your turn. 凸性的关键动作是: 用 时间共享 把两个编码方案组合起来。新方案的平均失真是两个方案对应量的 加权平均, 而新方案的互信息 $I(X; \hat{X})$ 是加权平均的 上界。

Proposition 9.13 (连续性). 在通常条件下, $R(D)$ 是关于 D 的连续函数。

两个特殊点

Proposition 9.14 (零失真点). 当 $D = 0$ 时, 有失真编码退化为无失真编码。若信源为离散信源, 且零失真等价于完全正确恢复, 则

$$R(0) = I(X; X) = \underline{H(X)}.$$

若信源为连续信源, 在平方误差等常见失真度量下, 随着 $D \rightarrow 0$, 通常有

$$R(D) \rightarrow \underline{\infty}.$$

Proposition 9.15 (最大允许失真). 存在一个阈值 $D_{\max}$, 使得当 $D \geq D_{\max}$ 时, 可以不传输任何关于 X 的信息, 而在接收端固定输出某个重构符号 $\hat{x}$. 此时 X 与 $\hat{X}$ 独立, $I(X; \hat{X}) = \underline{0}$, 故

$$R(D) = 0, \quad D \geq D_{\max}.$$

其中

$$D_{\max} = \min_{\hat{x} \in \hat{\mathcal{X}}} \sum_{i=1}^n p(x_i) d(x_i, \hat{x}).$$

Your turn. 补全 $D_{\max}$ 的直观含义: 在 不发送信息 的情况下, 接收端固定选择一个最优重构符号, 所能达到的最小平均失真为 $D_{\max}$ 。

率失真曲线的整体图像

综合以上性质, $R(D)$ 的典型形状满足:

$$R(0) = H(X), \quad R(D) \text{ 单调非增且凸}, \quad R(D) = 0 \quad (D \geq D_{\max}).$$

它刻画了 压缩率 与 重构质量 之间的最优折中。

Your turn. 用一句话概括 $R(D)$ 回答的问题:

若允许平均失真不超过 D , 最少需要保留多少 比特 来描述信源?

本节小结

概念	作用
失真测度 $d(x, \hat{x})$	刻画原符号与重构符号之间的差异。
平均失真 $\bar{d} = E[d(X, \hat{X})]$	描述整体重构误差。
允许失真度 D	平均失真的上界。
试验信道 $p(\hat{x} x)$	描述编码/译码整体造成的随机映射。
率失真函数 $R(D)$	在失真约束下, 编码所需的最小信息率。

10 连续信源的限失真编码

为什么 $R(D)$ 关于 D 是单调非增的? 从可行集合中具体信源的 $R(D)$ 计算, 例如二元对称信源在汉明失真下的率失真函数。

□□□□ 连续信源要先变成离散信源，才能进入前几节的编码框架。

声音、图像等模拟信号在时间和幅度上都是连续的。要把它们纳入限失真编码，必须经历采样、量化、编码三步：采样把时间离散化，量化把幅度离散化，编码把符号比特化。其中采样定理保证时间离散化可以不丢信息，而量化则不可避免地引入失真，成为连续信源限失真编码的核心。

从模拟信号到比特流

Trigger. 当题目给出一个连续波形并要求压缩时，先画出这条链路。

连续信源编码的标准流程可以写成

$$x(t) \xrightarrow{\text{采样}} x[n] = x(nT_s) \xrightarrow{\text{量化}} x_q[n] \xrightarrow{\text{编码}} \text{比特流}.$$

Definition 10.1 (采样). 采样是以固定时间间隔 T_s 从连续信号 $x(t)$ 中提取样本，得到离散时间序列

$$x[n] = x(nT_s), \quad n \in \mathbb{Z}.$$

T_s 称为 采样周期， $f_s = 1/T_s$ 称为 采样频率。这一步完成的是时间的离散化。

Definition 10.2 (量化). 量化是把每个采样值的连续幅度映射到有限个量化电平之一：

$$Q : \mathbb{R} \rightarrow \{y_1, y_2, \dots, y_M\}.$$

这一步完成的是幅度的离散化，也是失真的主要来源。

Definition 10.3 (编码). 编码是把量化后的离散符号转换成二进制码字，以便存储或传输。这一步完成的是符号化。

Your turn. 把三步与它们的作用对应起来：

采样：时间离散化， 量化：幅度离散化， 编码：符号化。

采样的频谱直觉

采样在时域上相当于用冲激串乘以原信号，在频域上使原频谱以 f_s 为周期重复。如果重复后的频谱互不重叠，就可以用滤波器把原信号完整恢复出来；如果重叠，就会产生混叠，信息永久丢失。

低通采样定理

Trigger. 当信号频谱集中在低频附近时，先用这个定理判断最小采样率。

Theorem 10.4 (低通采样定理, Shannon–Nyquist). 设实信号 $x(t)$ 是带限的，最高频率为 W (即频谱只在 $[-W, W]$ 内非零)。则当采样频率满足

$$f_s \geq \underline{2W}$$

时， $x(t)$ 可由样本 $x(nT_s)$ 完全重建。最小采样率 $2W$ 称为 Nyquist 速率，对应采样周期 $1/(2W)$ 称为 Nyquist 间隔。

Example 10.5. 某低通信号最高频率 $W = 4 \text{ kHz}$ ，则 Nyquist 速率为

$$f_s \geq 2W = \underline{8 \text{ kHz}}.$$

电话语音通常取 8 kHz 采样，正是基于这一结论。

Your turn. 若信号最高频率为 $W = 10 \text{ kHz}$ ，则不产生混叠的最小采样率为

$$f_{s,\min} = \underline{20 \text{ kHz}}.$$

混叠失真

Definition 10.6 (混叠). 若采样频率不满足 $f_s \geq 2W$ ，频谱复制后会发生 重叠。此时不同频率成分在采样后变得不可区分，这种现象称为 混叠 (aliasing)。混叠一旦发生，后续滤波无法恢复原始信号。

Your turn. 判断下列情况是否会产生混叠：

$W = 3 \text{ kHz}, f_s = 5 \text{ kHz}$: 会 ; $W = 3 \text{ kHz}, f_s = 8 \text{ kHz}$: 不会 .

带通采样定理

Trigger. 当信号是频带受限而不是基带受限时，可以用更低的采样率。

Proposition 10.7 (带通采样定理). 设实带通信号占据频段 $[f_L, f_H]$, 带宽 $B = f_H - f_L$ 。令 $m = \lfloor f_H/B \rfloor$ 。为保证采样后频谱不重叠, 采样率应满足

$$f_s \geq \frac{2f_H}{m}.$$

特别地, 若 f_H 是 B 的整数倍, 则最低采样率可降到

$$f_{s,\min} = \underline{2B},$$

远低于低通采样要求的 $2f_H$ 。

Example 10.8. 设 $f_L = 100 \text{ kHz}$, $f_H = 110 \text{ kHz}$, 则 $B = 10 \text{ kHz}$, $m = \lfloor 110/10 \rfloor = 11$ 。带通最小采样率为

$$f_{s,\min} = \frac{2 \times 110 \text{ kHz}}{11} = \underline{20 \text{ kHz}},$$

而低通采样要求 $2f_H = 220 \text{ kHz}$ 。

Your turn. 设带通信号 $f_L = 20 \text{ kHz}$, $f_H = 30 \text{ kHz}$, 则带宽 $B = \underline{10 \text{ kHz}}$, $m = \underline{3}$, 带通最小采样率为

$$f_{s,\min} = \underline{20 \text{ kHz}}.$$

重建

Proposition 10.9 (理想重建). 若采样满足相应的采样定理, 则原信号可由样本通过理想滤波器恢复。

对低通信号: 用增益为 T_s 、截止频率为 $f_s/2$ 的 理想低通滤波器, 恢复公式为

$$x(t) = \sum_{n=-\infty}^{\infty} x(nT_s) \operatorname{sinc}\left(\frac{t - nT_s}{T_s}\right),$$

其中 $\operatorname{sinc}(u) = \sin(\pi u)/(\pi u)$ 。

对带通信号: 用中心频率位于信号频带中心的 理想带通滤波器 恢复。

基带信号的理想重建 (从卷积出发)。只证低通情形; 带通情形只需把低通滤波器换成覆盖信号频带的带通滤波器。

采样在时域上等价于用冲激串调制原信号, 得到

$$x_s(t) = x(t) \sum_{n=-\infty}^{\infty} \delta(t - nT_s) = \sum_{n=-\infty}^{\infty} x(nT_s) \delta(t - nT_s).$$

它的频谱 $X_s(f)$ 是原频谱 $X(f)$ 以 f_s 为周期的重复；低通采样定理保证这些副本互不重叠。为恢复 $x(t)$ ，用一个理想低通滤波器保留基带并补偿采样引入的幅度缩放：

$$H(f) = \begin{cases} T_s, & |f| \leq f_s/2, \\ 0, & |f| > f_s/2. \end{cases}$$

其冲激响应为

$$h(t) = \mathcal{F}^{-1}\{H(f)\} = T_s \int_{-f_s/2}^{f_s/2} e^{j2\pi ft} df = \text{sinc}(t/T_s).$$

把采样序列 $x_s(t)$ 与 $h(t)$ 做卷积，即得重建信号

$$\begin{aligned} \hat{x}(t) &= x_s(t) * h(t) \\ &= \int_{-\infty}^{\infty} \sum_{n=-\infty}^{\infty} x(nT_s) \delta(\tau - nT_s) h(t - \tau) d\tau \\ &= \sum_{n=-\infty}^{\infty} x(nT_s) h(t - nT_s). \end{aligned}$$

代入 $h(t) = \text{sinc}(t/T_s)$ ，就得到 sinc 插值公式

$$x(t) = \sum_{n=-\infty}^{\infty} x(nT_s) \text{sinc}\left(\frac{t - nT_s}{T_s}\right).$$

■

Your turn. 复述理想重建证明的关键动作：

- (1) 采样在时域写成冲激串调制： $x_s(t) = x(t) \sum_n \delta(t - nT_s) = \sum_n x(nT_s) \delta(t - nT_s)$ ；
- (2) 用增益为 T_s 、截止频率为 $f_s/2$ 的理想低通滤波器取出基带；
- (3) 求出滤波器冲激响应 $h(t) = \underline{\text{sinc}(t/T_s)}$ ；
- (4) 将 $x_s(t)$ 与 $h(t)$ 做 卷积，得到 sinc 插值公式。

标量量化的基本模型

Definition 10.10 (标量量化). 标量量化是对采样序列样值进行量化。它是一个从 $\mathbb{R}$ 到量化电平集合的映射：

$$Q : \mathbb{R} \rightarrow \{y_1, y_2, \dots, y_M\}.$$

具体地，每个实值样本 x 被划分到某个区间，并用该区间对应的代表值表示：

$$Q(x) = y_k, \quad \text{当 } x \in (t_{k-1}, t_k], \quad k = 1, 2, \dots, M.$$

其中 M 是量化电平数 $\{t_k\}$ 是 决策边界， $\{y_k\}$ 是 量化电平。量化输出就是第 9 节的重构变量：

$$\hat{X} = Q(X) \in \{y_1, \dots, y_M\}.$$

■ **Definition 10.11** (量化误差与量化噪声功率). 量化误差定义为

$$e = x - Q(x).$$

若把 e 看成加性噪声, 则量化噪声功率为

$$N_q = E[(X - Q(X))^2].$$

■ **Definition 10.12** (量化信噪比). 设输入信号功率为 $P_X = E[X^2]$, 则量化信噪比定义为

$$\text{SNR} = \frac{P_X}{N_q},$$

常用分贝表示为

$$\text{SNR}_{\text{dB}} = 10 \log_{10} \frac{P_X}{N_q}.$$

■ **Example 10.13.** 若输入功率 $P_X = 4$, 量化噪声功率 $N_q = 0.01$, 则

$$\text{SNR} = 400, \quad \text{SNR}_{\text{dB}} = 26 \text{ dB}.$$

均匀量化器

Trigger. 最简单也最常用的量化器: 所有区间一样大。

■ **Definition 10.14** (均匀量化器). 若各量化区间长度相等, 即

$$\Delta = t_k - t_{k-1}, \quad k = 1, 2, \dots, M,$$

则称为均匀量化器, Δ 称为 量化步长。

■ **Proposition 10.15** (均匀输入的量化噪声功率). 设输入 X 在 $[-V, V]$ 上均匀分布, 采用 M 电平均匀量化器, 则量化步长 $\Delta = 2V/M$, 量化噪声功率为

$$N_q = \frac{\Delta^2}{12}.$$

■ **Example 10.16.** 设 X 在 $[-1, 1]$ 均匀分布, 用 $M = 8$ 电平均匀量化, 则 $\Delta = 2/8 = 0.25$,

$$N_q = \frac{(0.25)^2}{12} \approx \underline{5.21 \times 10^{-3}}.$$

信号功率 $P_X = 1/3$ ，所以

$$\text{SNR} = \frac{1/3}{5.21 \times 10^{-3}} \approx \underline{64} \approx \underline{18.1 \text{ dB}}.$$

Your turn. 把均匀量化 SNR 与量化比特数 $R = \log_2 M$ 的关系填出来：

$$\text{SNR}_{\text{dB}} \approx 6.02R + C,$$

其中 C 是与 输入信号统计特性 有关的常数。对 $[-V, V]$ 均匀输入， $C = \underline{0 \text{ dB}}$ 。

最佳量化器

Trigger. 给定量化电平数，想让量化噪声最小，就要求解 Lloyd-Max 条件。

Proposition 10.17 (Lloyd-Max 最优条件). 给定量化电平数 M ，使量化噪声功率 N_q 最小的标量量化器满足：

1. 决策边界在两相邻量化电平中点：

$$t_k = \frac{y_k + y_{k+1}}{2}, \quad k = 1, 2, \dots, M-1.$$

2. 每个量化电平是对应区间上的条件期望：

$$y_k = \mathbb{E}[X \mid t_{k-1} \leq X < t_k].$$

Proof. 把 N_q 对 t_k 和 y_k 分别求偏导并令其为零即可。对边界 t_k 求导，导数为零要求 t_k 到 y_k 与 y_{k+1} 的距离相等，即中点条件。对电平 y_k 求导，导数为零要求 y_k 是区间 $[t_{k-1}, t_k]$ 上的条件均值，即质心条件。这两个条件通常需要 迭代。

Your turn. 对均匀输入，Lloyd-Max 条件退化为均匀量化器：因为条件期望正好落在区间 中点，决策边界也正好在相邻电平 中点。

采样定理解决的是“时间离散化会不会丢信息”；量化解解决的是“幅度离散化能省多少比特、会引入多少失真”。把二者合起来，就得到连续信源限失真编码的实际框架：先采样，再量化，最后对量化符号做无失真或限失真编码。这正是第 9 节 $R(D)$ 的物理入口：量化器的设计直接决定了失真 D ，而编码器在 D 约束下逼近 $R(D)$ 。

11 矢量量化

□□□□ 标量量化一次只压一个样值；矢量量化把相邻样值打包，利用它们之间的相关性。

矢量量化是对采样序列中每 k 个样值的联合量化，属于多维量化。它充分利用各样值间的 统计相关性，因此在相同失真约束下，编码效率 高于标量量化。

基本原理

Trigger. 先把 k 个样值看成向量，再把 k 维空间切成若干子空间。

Definition 11.1 (矢量量化). 将模拟信号采样序列中每 k 个样值分一组，得到 k 维向量

$$X = (x_1, x_2, \dots, x_k),$$

其统计特性由联合概率密度 $p(x_1, x_2, \dots, x_k)$ 描述。将 k 维空间分割成 L 个子空间 $\{C_i\}_{i=1}^L$ ，满足

$$\bigcup_{i=1}^L C_i = \mathbb{R}^k.$$

每个子空间 C_i 对应一个 重构矢量（也称量化矢量或码字）

$$y_i = (y_{i1}, y_{i2}, \dots, y_{ik}) \in \mathbb{R}^k, \quad i = 1, 2, \dots, L.$$

若输入向量落在 C_i 内，即 $X \in C_i$ ，则将其量化为码字 y_i （即重构矢量）：

$$Q(X) = y_i.$$

矢量量化可看作映射

$$Q : \mathbb{R}^k \rightarrow \mathbb{R}^k.$$

量化输出就是第 9 节的重构变量：

$$\hat{X} = Q(X) \in \{y_1, \dots, y_L\}.$$

量化方式	输入/输出	关键对象
标量量化	$Q : \mathbb{R} \rightarrow \{y_k\}$	决策边界 $\{t_k\}$ 、量化电平 $\{y_k\}$
矢量量化	$Q : \mathbb{R}^k \rightarrow \mathbb{R}^k$	子空间 $\{C_i\}$ 、码本 $\{y_i\}$

Your turn. 用一句话复述矢量量化的基本流程：

- (1) 每 k 个样值组成向量 X ；
- (2) 把 $\mathbb{R}^k$ 分成 L 个子空间 $\{C_i\}$ ；
- (3) 若 $X \in C_i$ ，则输出码字 y_i 。

失真测度与平均失真

Trigger. 最常用的失真度量是均方误差。

Definition 11.2 (矢量量化的失真测度). 对输入向量 X 与重构矢量 y_i , 常用均方误差失真:

$$d(X, y_i) = \sum_{j=1}^k (x_j - y_{ij})^2 = \|X - y_i\|_2^2.$$

Definition 11.3 (总平均失真). 矢量量化的总平均失真定义为

$$D = \sum_{i=1}^L P(X \in C_i) \cdot \mathbb{E}[d(X, y_i) | X \in C_i],$$

也可写成积分形式:

$$D = \sum_{i=1}^L P(X \in C_i) \int_{X \in C_i} d(X, y_i) p(x) dx, \quad X \in \mathbb{R}^k.$$

其中 $P(X \in C_i) = \int_{C_i} p(x) dx$ 是向量落入子空间 C_i 的概率。

Example 11.4. 设 $k = 2$, $L = 2$, $P(X \in C_1) = 0.6$, $P(X \in C_2) = 0.4$ 。若 $\mathbb{E}[d(X, y_1) | X \in C_1] = 1.2$, $\mathbb{E}[d(X, y_2) | X \in C_2] = 2.5$, 则

$$D = 0.6 \times 1.2 + 0.4 \times 2.5 = \underline{1.72}.$$

最佳矢量量化的两个必要条件

Trigger. 给定码本大小 L , 想让平均失真 D 最小, 就要同时满足最近邻与质心。

Proposition 11.5 (最佳矢量量化的两个必要条件). 给定码本大小 L , 使总平均失真 D 最小的矢量量化器满足:

1. 最近邻原则 (分割空间):

$$C_i = \{X : d(X, y_i) \leq d(X, y_j), j \neq i\} = \{X : \|X - y_i\|_2^2 \leq \|X - y_j\|_2^2, j \neq i\}.$$

2. 质心原则 (码字设计):

$$y_i = \frac{\int_{X \in C_i} X p(x) dx}{\int_{X \in C_i} p(x) dx}.$$

Remark 11.6 (LBG 算法). 上述两条件互相依赖：固定码本时最优划分是最近邻，固定划分时最优码字是质心。Linde、Buzo 和 Gray (1980) 据此给出交替迭代算法，常称为 **LBG 算法**：先给定初始码本，再反复用最近邻更新划分、用质心更新码字，直到平均失真收敛。

Your turn. 对照第 10 节 Lloyd–Max：标量里决策边界在相邻电平的 中点，矢量里子空间由 最近邻 原则划分；标量里量化电平是区间上的 条件期望，矢量里码字是子空间上的 质心。

标量量化把每个样值独立离散化，忽略了相邻样值之间的相关性；矢量量化把多个样值作为一个向量整体编码，在 k 维空间里用 L 个码字近似整个联合分布。这正是第 9 节 $R(D)$ 的实际实现路径之一：码本大小 L 决定每向量码率 $\log_2 L$ ，折合到每样值约为

$$R \approx \frac{1}{k} \log_2 L,$$

而 LBG 条件则在给定 L 时最小化平均失真 D 。

? LBG 两条件：
最近邻与质心。

下一节接有记忆信源编码：先削弱相关性，再对近似独立分量编码（如 transform coding）。