




信源编码的统计基础

通信原理：从概率模型到压缩极限

fanzuituanhuo

July 9, 2026

dyed in indigo, madder & weld; ruled in iron-gall. woven on LOOM.

总览地图

□□□□ 先抓住一条主线：信源编码先建模不确定性，再讨论在什么失真约束下能压到多低。

本页笔记的 spine 是：先建立信源统计模型，再选择失真约束，最后用信息度量给出可达到的压缩极限。单符号、序列、连续和有记忆信源给出“要编码的对象”；熵、条件熵、联合熵和互信息给出“能压缩到哪里”的语言。后面的无失真编码、限失真编码和变换编码都会沿着这条线展开。

一眼对照

对象	符号	统计描述
离散单符号信源	$X, \mathcal{X} = \{x_1, x_2, \dots, x_n\}$	用概率质量函数 $p(x_i)$ 描述每个符号出现的概率。
连续单符号信源	$X \in (a, b)$	用概率密度函数 $p(x)$ 描述取值附近的概率强度（本章不展开）。
离散消息序列信源	X^L	用 L 维联合分布 $p(x_1, x_2, \dots, x_L)$ 描述整段序列。
无记忆序列信源	$X_1, \dots, X_L$ 相互独立	联合概率可以分解为各符号概率的乘积。
信息熵	$H(X)$	度量一个信源平均不确定性，等于自信息量的数学期望。
条件熵与联合熵	$H(Y X), H(X, Y)$	描述已知一个信源后另一个信源的剩余不确定性，以及两个信源整体的不确定性。
互信息	$I(X; Y)$	描述观察 Y 后关于 X 的不确定性减少量。

后续路线

编码问题	核心量	本章前置知识的作用
无失真离散信源编码	$H(X)$	熵给出平均码长的理论下界，编码要尽量逼近这个下界。
限失真信源编码	$R(D)$	在允许平均失真 D 时，用率失真函数描述最小所需码率。
连续信源限失真编码	$R(D), d(x, \hat{x})$	连续取值需要指定失真度量和重构变量 $\hat{X}$ 。
有记忆信源编码	相关性、变换	先削弱样本间相关性，再对近似独立的分量编码，例如 transform coding。

1 通信系统与信源编码

□□□□ 这部分回答：为什么一上来就要研究信源的统计特性。

通信的起点是信源，它产生待传输的信息。信道只是承载信号的通道；真正决定编码能否有效、系统能否可靠的，是信源和信道各自的统计特性。

通信技术的两个性能维度

Trigger. 当题目问“通信系统为什么要统计建模”时，先分清两个目标。

目标 依赖的统计特性

有效性 主要取决于信源统计特性。信源越有冗余，越有压缩空间。

可靠性 主要取决于信道统计特性。噪声、干扰和差错概率决定抗干扰设计。

Definition 1.1 (信源). 信源是产生消息或信息的对象。它的输出通常不是确定值，而是具有 随机性 的随机对象。

Definition 1.2 (信道). 信道是传递信号经过的通道。它会影响传输的可靠性，因此常用信道的 统计特性 来描述噪声和差错。

Definition 1.3 (信源编码). 信源编码是在分析信源统计特性的基础上，用尽可能少的码率表示信源输出。无失真编码要求接收端能够完全恢复原消息；限失真编码允许在给定失真约束内恢复 近似消息。

Your turn. 把“有效性”和“可靠性”各自对应的对象填出来：

有效性 $\leftrightarrow$ 信源 , 可靠性 $\leftrightarrow$ 信道 .

? 信源编码为什么首先要研究信源统计特性?

■ 2 信源分类与单符号信源

□□□□ 先看一次输出一个随机符号的信源，这是后面序列信源的基本积木。

信源可以按输出的对象来分：如果每次输出一个符号，叫单符号信源；如果连续输出一串符号，叫消息序列信源。也可以按取值集合分为离散信源和连续信源。

分类地图

分类角度	常见类型
------	------

按取值集合	离散信源，也可称数字信源；连续信源，也可称模拟信源。
-------	----------------------------

按输出结构	单符号信源；消息序列信源，也就是随机过程形式的信源。
-------	----------------------------

Definition 2.1 (离散单符号信源). 设离散单符号信源为随机变量 X ，其取值集合为

$$\mathcal{X} = \{x_1, x_2, \dots, x_n\}.$$

若每个符号 x_i 出现的概率为 $p(x_i)$ ，则该信源的统计描述为

$$\begin{pmatrix} x_1 & x_2 & \cdots & x_n \\ p(x_1) & p(x_2) & \cdots & p(x_n) \end{pmatrix},$$

其中

$$0 \leq p(x_i) \leq 1, \quad \sum_{i=1}^n p(x_i) = \underline{1}.$$

Definition 2.2 (连续单符号信源). 若信源输出 X 是连续随机变量，例如 $X \in (a, b)$ ，则通常用概率密度函数 $p(x)$ 描述。这里的 $p(x)$ 不是某一点的概率；当 dx 很小时，

$$p(x) dx \approx P\{x \leq X < x + dx\}.$$

更一般地，

$$P\{a \leq X \leq b\} = \int_a^b p(x) dx.$$

也就是说， $p(x)$ 描述的是单位长度小区间中的 概率密度。

Remark 2.3. 离散情形用“概率质量”看每个符号，连续情形用“概率密度”看区间附近。二者的共同点是：都在回答信源输出落在某些取值上的可能性。本章聚焦离散信源；连续信源及其微分熵将在后续课程中展开。

Your turn. 判断下面两个对象分别属于哪类信源：

二进制符号 $\{0, 1\}$: 离散信源 , 连续取值 $X \in (a, b)$: 连续信源 .

? 为什么连续信源中 $p(x)$ 通常叫概率密度而不是概率?

■ 3 离散消息序列信源的统计描述

□□□□ 序列信源的关键变化：输出不再是一个符号，而是一整段符号向量。

消息序列信源关心的不是单个输出符号，而是一段长度为 L 的符号序列。因此统计描述从一维概率分布升级为 L 维联合概率分布。

从符号集到序列集

设单个符号的取值集合为 $\mathcal{X}$ ，则长度为 L 的序列取值集合可写成

$$\mathcal{X}^L = \mathcal{X} \times \mathcal{X} \times \cdots \times \mathcal{X},$$

一次输出的消息序列为

$$X^L = (X_1, X_2, \dots, X_L),$$

它是一个 L 维随机向量。某个具体序列可写为

$$x^L = (x_1, x_2, \dots, x_L).$$

Definition 3.1 (L 维联合分布). 离散消息序列信源的统计特性由联合概率

$$p(x^L) = p(x_1, x_2, \dots, x_L)$$

描述。一般地，它可以按条件概率链式分解为

$$p(x_1, x_2, \dots, x_L) = p(x_1)p(x_2|x_1) \cdots p(x_L|x_1, x_2, \dots, x_{L-1}).$$

这个式子说明：序列中后一个符号的概率可能依赖于 前面已经出现的符号。

Proposition 3.2 (序列取值个数). 若单符号信源有 n 个可能取值，则长度为 L 的离散消息序列共有

$$n^L$$

个可能序列。

Example 3.3. 若单符号集合是 $\{0, 1\}$ ，长度 $L = 3$ ，则全部序列为

$$000, 001, 010, 011, 100, 101, 110, 111.$$

这里共有 $2^3 = 8$ 个可能序列。

Your turn. 若四进制符号集合为 $\{0, 1, 2, 3\}$ ，序列长度 $L = 2$ ，可能序列数为

$$\underline{16}.$$

? 为什么序列信源的概率模型一般要用联合分布，而不是只写每个符号自己的概率？

4 无记忆信源与等概二进制例子

□□□□ 无记忆是最常见的简化：过去的符号不影响现在的符号。

真实序列信源可能有记忆，比如自然语言中前后字符相关。无记忆信源是一个重要特例：序列中各符号统计独立，所以联合分布可以直接分解成乘积。

Definition 4.1 (无记忆离散信源). 若序列中的各个符号相互统计独立，则称该序列

信源为无记忆信源。此时

$$p(x_1, x_2, \dots, x_L) = \prod_{\ell=1}^L p(x_\ell).$$

它的核心条件是序列中前后符号之间没有 统计依赖。

Remark 4.2. 有记忆信源的相关性比较复杂，不能简单把联合概率写成各项乘积。例如某些文字、语音或图像信源，当前符号往往受前面符号影响。后面的有记忆信源编码会围绕一个目标展开：先解除或削弱相关性，再分别编码近似独立的分量。

Example 4.3 (三位等概二进制序列). 设单个符号 0 和 1 等概出现：

$$p(0) = p(1) = \frac{1}{2}.$$

当 $L = 3$ 时，可能序列共有 $2^3 = 8$ 个。若信源无记忆，则每个具体序列的概率为

$$p(x_1, x_2, x_3) = p(x_1)p(x_2)p(x_3) = \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{8}.$$

Your turn. 仍设 $p(0) = p(1) = 1/2$ 。请写出序列 101 的概率计算：

$$p(101) = p(1)p(0)p(1) = \underline{\frac{1}{2}} \cdot \underline{\frac{1}{2}} \cdot \underline{\frac{1}{2}} = \underline{\frac{1}{8}}.$$

Your turn. 如果 $p(0) = 0.7$, $p(1) = 0.3$ ，且仍为无记忆信源，请计算序列 001 的概率：

$$p(001) = \underline{0.7} \cdot \underline{0.7} \cdot \underline{0.3} = \underline{0.147}.$$

复习时可以按这个顺序默写：信源产生消息，信源编码利用统计冗余；单符号信源写 X 和 $p(x_i)$ ；序列信源写 X^L 和联合分布；无记忆时联合分布变成乘积。接下来要问的是：这些概率分布对应的“不确定性”到底有多大，以及这种不确定性如何限制压缩码率？

■ 5 信息熵：单符号离散信源的不确定性

□□□□ 熵不是某次收到的信息量，而是信源在统计意义上的平均不确定性。

前面我们已经把信源写成概率分布。信息熵 $H(X)$ 做的事，是把这个概率分布压缩成一个数：信源平均有多不确定，平均需要多少信息才能消除这种不确定性。

定义

Trigger. 当题目给出离散信源 X 、取值集合 $\mathcal{X} = \{x_1, \dots, x_n\}$ 及概率 $p(x_i)$ 时，用这个公式。

Definition 5.1 (信息熵). 设离散单符号信源 X 的概率分布为 $p(x_i)$ 。它的信息熵定义为

$$H(X) = \mathbb{E}[-\log p(X)] = -\sum_{i=1}^n p(x_i) \log p(x_i).$$

其中 $\mathbb{E}$ 表示数学期望。信息熵度量的是信源的 平均不确定性。

对数底与单位

对数底	单位	含义
2	bit	最常用，表示二进制信息单位。
e	nat	自然对数单位。
10	Hartley 或十进制单位	十进制对数单位。

Remark 5.2. 若某个符号概率为 0，约定 $0 \log 0 = 0$ 。直觉上，不可能发生的符号不会贡献平均不确定性。

二进制信源

Example 5.3 (二进制熵函数). 设二进制信源 $X \in \{0, 1\}$ ，且

$$p(0) = p, \quad p(1) = 1 - p.$$

若以 2 为对数底，则

$$H(X) = -p \log_2 p - (1 - p) \log_2 (1 - p) \triangleq h(p).$$

当 $p = \frac{1}{2}$ 时，两个符号等概，二进制熵达到最大值 1 bit。

n 进制信源的最大熵

Proposition 5.4 (等概分布最大熵). 若 n 进制离散信源 X 的取值集合为 $\mathcal{X} = \{x_1, \dots, x_n\}$ ，则

$$H(X) \leq \log n.$$

等号成立当且仅当

$$p(x_1) = p(x_2) = \dots = p(x_n) = \frac{1}{n}.$$

Proof. 记 $p_i = p(x_i)$ 。若某些 $p_i = 0$ ，这些项按约定 $0 \log 0 = 0$ ，不会贡献熵。先考虑所有 $p_i > 0$ 的情形：

$$H(X) = -\sum_{i=1}^n p_i \log p_i = \sum_{i=1}^n p_i \log \frac{1}{p_i}.$$

因为 $\log t$ 是凹函数，由 Jensen 不等式，

$$\sum_{i=1}^n p_i \log \frac{1}{p_i} \leq \log \left(\sum_{i=1}^n p_i \frac{1}{p_i} \right) = \log n.$$

因此 $H(X) \leq \log n$ 。

等号成立时，Jensen 不等式的等号条件要求

$$\frac{1}{p_1} = \frac{1}{p_2} = \cdots = \frac{1}{p_n},$$

也就是

$$p_1 = p_2 = \cdots = p_n.$$

再由 $\sum_{i=1}^n p_i = 1$ ，得到

$$p_1 = p_2 = \cdots = p_n = \frac{1}{n}.$$

反过来，如果 $p_i = 1/n$ ，则

$$H(X) = - \sum_{i=1}^n \frac{1}{n} \log \frac{1}{n} = \log n,$$

所以等号确实成立。

若只有 $k < n$ 个符号概率非零，则同样的证明给出

$$H(X) \leq \log k < \log n,$$

因此在 n 个可能符号中达到最大熵时，必须所有符号都以相同概率出现。 ■

Your turn. 复述最大熵证明的关键一步：把

$$H(X) = \sum_{i=1}^n p_i \log \frac{1}{p_i}$$

看成对凹函数 $\log t$ 的加权平均，因此由 Jensen 不等式得到

$$H(X) \leq \log \left(\sum_{i=1}^n p_i \frac{1}{p_i} \right) = \underline{\log n}.$$

信息量描述一次接收后不确定性减少了多少；**信息熵**描述接收前信源平均有多不确定。前者偏向一次事件，后者偏向整个信源的统计平均。对无失真离散信源编码，熵会成为平均码长的理论下界；对限失真编码，这个角色会由 $R(D)$ 接过去。

? 为什么等概信源的不确定性最大?

■ 6 条件熵与联合熵

□□□□ 两个随机信源放在一起时，要区分“总不确定性”和“知道一个以后剩下多少”。

现在有两个离散信源 X 和 Y 。如果知道了 X ，对 Y 的不确定性通常会下降。这个剩余不确定性就是条件熵；把 (X, Y) 当成一个整体看，就是联合熵。

条件熵

Trigger. 当题目出现“已知 X 后 Y 还剩多少不确定性”时，用 $H(Y|X)$ 。

Definition 6.1 (条件熵). 设 X 的取值为 $x_1, \dots, x_n$ ， Y 的取值为 $y_1, \dots, y_m$ 。条件熵定义为

$$H(Y|X) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(y_j|x_i) = \mathbb{E}[-\log p(Y|X)].$$

它度量的是已知 X 后， Y 的 剩余不确定性。

Definition 6.2 (联合熵). 联合熵把二元随机向量 (X, Y) 看成一个整体：

$$H(X, Y) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(x_i, y_j).$$

它度量两个信源共同输出时的总体不确定性。

Proposition 6.3 (熵的链式法则). 联合熵可以分解为

$$H(X, Y) = H(X) + H(Y|X) = H(Y) + H(X|Y).$$

Proof. 从联合概率的链式分解开始：

$$p(x_i, y_j) = p(x_i)p(y_j|x_i).$$

代入联合熵定义，并把乘积的对数拆成和：

$$\begin{aligned} & - \sum_{i,j} p(x_i, y_j) \log [p(x_i)p(y_j|x_i)] \\ &= - \sum_{i,j} p(x_i, y_j) \log p(x_i) - \sum_{i,j} p(x_i, y_j) \log p(y_j|x_i). \end{aligned}$$

第一项中 $\sum_j p(x_i, y_j) = p(x_i)$ ，所以它等于 $H(X)$ ；第二项正是 $H(Y|X)$ 。因此

$$H(X, Y) = H(X) + H(Y|X).$$

同理也可以先写 $p(x_i, y_j) = p(y_j)p(x_i|y_j)$ ，得到

$$H(X, Y) = H(Y) + H(X|Y).$$

Your turn. 复述链式法则证明中最关键的一步：

$$\log [p(x_i)p(y_j|x_i)] = \underline{\log p(x_i) + \log p(y_j|x_i)}.$$

Shannon 不等式

Proposition 6.4 (条件不会增加不确定性).

$$H(Y|X) \leq H(Y), \quad H(X|Y) \leq H(X).$$

也就是说, 知道另一个随机变量, 只会减少或保持不确定性, 不会增加平均不确定性。

Your turn. 若 X 和 Y 相互独立, 则 Y 在已知 X 后没有变得更确定, 因此

$$H(Y|X) = \underline{H(Y)}, \quad H(X, Y) = \underline{H(X)} + \underline{H(Y)}.$$

? 为什么 $H(X, Y)$ 既可以写成 $H(X) + H(Y|X)$, 也可以写成 $H(Y) + H(X|Y)$?

7 互信息：不确定性的减少量

□□□□ 互信息把“收到一个信源后, 对另一个信源多了解了多少”变成公式。

如果 X 是信源, Y 是信宿或接收端观察到的量, 那么互信息 $I(X; Y)$ 衡量的是: 观察 Y 以后, 关于 X 的不确定性平均减少了多少。

定义与等价写法

Definition 7.1 (互信息). 互信息定义为

$$I(X; Y) = H(X) - H(X|Y).$$

等价地, 也可以写成

$$I(X; Y) = H(Y) - H(Y|X) = H(X) + H(Y) - H(X, Y).$$

因此, 互信息可以看成 X 与 Y 共享的那部分信息。

Proposition 7.2 (概率形式). 互信息也可以写成联合分布与边缘分布的比值:

$$I(X; Y) = \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)}.$$

等价地,

$$I(X; Y) = \mathbb{E} \left[\log \frac{p(X|Y)}{p(X)} \right] = \mathbb{E} \left[\log \frac{p(Y|X)}{p(Y)} \right].$$

Proof. 从

$$I(X; Y) = H(X) - H(X|Y)$$

出发。因为

$$p(x_i) = \sum_{j=1}^m p(x_i, y_j),$$

所以

$$\begin{aligned} H(X) &= - \sum_{i=1}^n p(x_i) \log p(x_i) \\ &= - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(x_i). \end{aligned}$$

另一方面,

$$H(X|Y) = - \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log p(x_i|y_j).$$

两式相减, 得到

$$\begin{aligned} I(X; Y) &= \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) [\log p(x_i|y_j) - \log p(x_i)] \\ &= \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log \frac{p(x_i|y_j)}{p(x_i)}. \end{aligned}$$

再由条件概率

$$p(x_i|y_j) = \frac{p(x_i, y_j)}{p(y_j)}$$

可得

$$I(X; Y) = \sum_{i=1}^n \sum_{j=1}^m p(x_i, y_j) \log \frac{p(x_i, y_j)}{p(x_i)p(y_j)}.$$

这也说明

$$I(X; Y) = \mathbb{E} \left[\log \frac{p(X|Y)}{p(X)} \right].$$

同理从 $I(X; Y) = H(Y) - H(Y|X)$ 出发, 可以得到

$$I(X; Y) = \mathbb{E} \left[\log \frac{p(Y|X)}{p(Y)} \right].$$

■

Your turn. 复述互信息等价式证明的关键动作:

$$H(X) = - \sum_i p(x_i) \log p(x_i) = - \sum_{i,j} \underline{p(x_i, y_j)} \log p(x_i),$$

所以 $H(X) - H(X|Y)$ 可以合并成同一个 (i, j) 双重求和。

性质

性质	含义
非负性	$I(X;Y) \geq 0$ 。平均来看，观察不会让不确定性“负减少”。
对称性	$I(X;Y) = I(Y;X)$ 。 Y 中关于 X 的信息量，等于 X 中关于 Y 的信息量。
独立时为零	若 X 与 Y 独立，则 $I(X;Y) = 0$ 。
完全确定时最大	若 Y 能完全确定 X ，则 $I(X;Y) = H(X)$ 。

Remark 7.3. 在固定信道转移概率 $p(y|x)$ 时， $I(X;Y)$ 是输入分布 $p(x)$ 的凹函数；在固定输入分布 $p(x)$ 时， $I(X;Y)$ 是信道转移概率 $p(y|x)$ 的凸函数。这解释了两个后续优化问题：固定信道 $p(y|x)$ 时，最大化 $I(X;Y)$ 得信道容量；固定失真约束时，最小化 $I(X;\hat{X})$ 得率失真函数 $R(D)$ 。

Your turn. 用熵的图像直觉填空：

$$I(X;Y) = H(X) - H(X|Y)$$

表示观察 Y 以后，关于 X 的不确定性减少了 $I(X;Y)$ 。

Your turn. 若 X 与 Y 独立，则 $p(x_i, y_j) = p(x_i)p(y_j)$ 。代入概率形式可得

$$I(X;Y) = \sum_{i,j} p(x_i, y_j) \log \frac{1}{p(x_i)p(y_j)} = \underline{0}.$$

■ 8 无失真离散信源编码

下一步接信源编码：无失真看 $H(X)$ ，限失真看 $R(D) = \min I(X; \hat{X})$ 。

□□□□ 这一节把前面的熵变成编码结论：若允许很长的分组，平均码率或平均码长可以逼近 $H(X)$ 。

无失真离散信源编码的核心问题是：把长度为 L 的信源序列 X^L 映射成码字，再由码字恢复出 $\hat{X}^L$ 。如果分组足够长，高概率序列集中在典型集里，于是只需要给典型序列分配码字，所需码字数量大约是 $2^{LH(X)}$ 。

编码模型

Trigger. 当题目出现 X^L 、码字集合 $\mathcal{U}^k$ 、编码映射和译码映射时，先画这条链。

Definition 8.1 (分组信源编码). 设离散无记忆信源的长度 L 输出序列取值于 $\mathcal{X}^L$, 码符号集合为 $\mathcal{U}$, 每个码字长度为 k , 则码字集合为 $\mathcal{U}^k$. 编码映射和译码映射分别为

$$f: \mathcal{X}^L \rightarrow \mathcal{U}^k, \quad g: \mathcal{U}^k \rightarrow \mathcal{X}^L.$$

整个过程可写为

$$X^L \xrightarrow{f} U^k \xrightarrow{g} \hat{X}^L,$$

其中 $\hat{X}^L$ 是译码恢复出来的 信源序列。

Remark 8.2. 若 k 为固定值, 就是等长编码; 若不同信源序列允许使用不同长度的码字, 就是变长编码。本节先看分组等长编码的基本极限。

什么叫无失真

Definition 8.3 (严格无失真与渐近无失真). 严格无失真要求对每个输入序列都有

$$\hat{X}^L = X^L.$$

更常用的渐近无失真用错误概率描述:

$$P_e^{(L)} = P\{\hat{X}^L \neq X^L\}.$$

若当 $L \rightarrow \infty$ 时存在一族编码方案使

$$P_e^{(L)} \rightarrow 0,$$

则称可以实现渐近无失真编码。

Your turn. 把“严格无失真”和“渐近无失真”的差别填出来:

严格无失真: $\hat{X}^L = \underline{X^L}$, 渐近无失真: $P_e^{(L)} \rightarrow \underline{0}$.

码率

Definition 8.4 (编码速率). 若码符号集合 $\mathcal{U}$ 的大小为 M , 每个信源分组长度为 L , 码字长度为 k , 则编码速率定义为

$$R = \frac{k}{L} \log_2 M$$

bit/source symbol。它表示平均每个信源符号需要多少二进制位来表示。

Example 8.5. 若用二进制码字, $M = 2$, 则

$$R = \frac{k}{L}.$$

若每个 $L = 4$ 的信源分组用 $k = 6$ 个二进制码元表示, 则码率为

$$R = \frac{6}{4} = 1.5 \text{ bit/source symbol}.$$

Your turn. 若码符号集合大小为 $M = 4$, 长度 $L = 5$ 的信源序列被编码成长度 $k = 6$ 的码字, 则

$$R = \frac{k}{L} \log_2 M = \frac{6}{5} \log_2 4 = \underline{2.4}.$$

熵给出的可达极限

Theorem 8.6 (离散无记忆信源无失真编码定理). 设离散无记忆信源 X 的熵为 $H(X)$. 对任意 $\epsilon > 0$, 若编码速率满足

$$R = \frac{k}{L} \log_2 M > H(X) + \epsilon,$$

则当 L 足够大时, 存在一族分组编码使错误概率

$$P_e^{(L)} < \delta$$

其中 $\delta > 0$ 可以任意小. 反过来, 若

$$R < H(X),$$

则不可能实现渐近无失真编码。

Remark 8.7. 这个定理的严格证明要用典型序列和大数定律, 后面讲无失真信源编码定理时再完整证明。这里先保留结论和直觉: 高概率序列集中在典型集里, 典型集大小约为 $2^{LH(X)}$, 所以只要码字数能覆盖典型集, 错误概率就可以随 L 增大而变小。

典型序列的角色

Definition 8.8 (典型集). 对长度为 L 的信源序列, 把概率接近 $2^{-LH(X)}$ 的高概率序列放入典型集, 记作 $A_\epsilon^{(L)}$ 。当 L 足够大时,

$$P\{X^L \in A_\epsilon^{(L)}\} > 1 - \delta,$$

并且典型集大小大约满足

$$|A_\epsilon^{(L)}| \leq 2^{L(H(X)+\epsilon)}.$$

典型集解释了为什么“不是所有 n^L 个序列都同等重要”。虽然长度为 L 的序列总数是 n^L ，但实际概率质量几乎都集中在典型集里。编码器只需要重点照顾典型序列，非典型序列造成的错误概率可以随着 L 增大而变小。

Your turn. 用典型集语言补完整个可达性思路：

$$P\{X^L \in A_\epsilon^{(L)}\} > 1 - \delta, \quad |A_\epsilon^{(L)}| \leq \frac{2^{L(H(X)+\epsilon)}}{\delta}.$$

因此只要

$$M^k \geq |A_\epsilon^{(L)}|,$$

就有足够多码字覆盖典型序列，也就是

$$R = \frac{k}{L} \log_2 M > \frac{H(X) + \epsilon}{1}.$$

变长编码：平均码长逼近熵

等长编码把每个长度为 L 的信源序列都塞进同样长的码字；变长编码则让高概率序列用短码字，低概率序列用长码字。它关心的不是固定码字长度 k ，而是平均码长 $\bar{K}$ 。

Definition 8.9 (平均码长). 设长度为 L 的信源序列 x^L 被编码成 m 元码字，码长为 $K(x^L)$ 。平均码长定义为

$$\bar{K} = \sum_{x^L \in \mathcal{X}^L} p(x^L) K(x^L).$$

因此

$$\frac{\bar{K}}{L}$$

表示每个信源符号平均需要的 m 元码符号数。

Theorem 8.10 (变长编码定理). 设 X 为离散无记忆信源，熵为 $H(X)$ ，码符号集合大小为 m 。对长度为 L 的信源扩展进行唯一可译变长编码时，任意唯一可译码都满足

$$\frac{\bar{K}}{L} \geq \frac{H(X)}{\log_2 m}.$$

另一方面，存在一族 m 元即时码，使

$$\frac{\bar{K}}{L} < \frac{H(X)}{\log_2 m} + \frac{1}{L}.$$

也就是说，通过增大分组长度 L ，变长编码的每符号平均码长可以任意逼近熵下界。

Proof. 先看下界。任意唯一可译码的码长必须满足 Kraft 不等式，因此它诱导的平均码长

不可能低于信源扩展熵对应的 m 元码符号数:

$$\bar{K} \geq \frac{H(X^L)}{\log_2 m}.$$

由于信源无记忆,

$$H(X^L) = LH(X),$$

所以

$$\frac{\bar{K}}{L} \geq \frac{H(X)}{\log_2 m}.$$

再看可达性。对每个序列取 Shannon 码长

$$K(x^L) = \lceil -\log_m p(x^L) \rceil,$$

则

$$K(x^L) < -\log_m p(x^L) + 1.$$

对 x^L 求平均, 得到

$$\bar{K} < \frac{H(X^L)}{\log_2 m} + 1 = \frac{LH(X)}{\log_2 m} + 1.$$

两边除以 L , 即得

$$\frac{\bar{K}}{L} < \frac{H(X)}{\log_2 m} + \frac{1}{L}.$$



Your turn. 复述变长编码定理的关键夹逼:

$$\frac{H(X)}{\log_2 m} \leq \frac{\bar{K}}{L} < \frac{\frac{H(X)}{\log_2 m} + \frac{1}{L}}{1}.$$

当 $m = 2$ 时, $\log_2 m = 1$, 所以

$$H(X) \leq \frac{\bar{K}}{L} < \frac{H(X) + \frac{1}{L}}{1}.$$



Definition 8.11 (编码效率). 把平均码长换算成 bit/source symbol:

$$R = \frac{\bar{K}}{L} \log_2 m.$$

编码效率定义为

$$\eta = \frac{H(X)}{R}.$$

当 R 越接近 $H(X)$, 编码效率越接近 1。

Your turn. 若采用二进制变长编码，且分组长度 L 足够大，使 $1/L < \epsilon$ ，则定理给出

$$H(X) \leq \frac{\bar{K}}{L} < H(X) + \underline{\epsilon}.$$

这说明二进制变长编码的平均码长可以逼近 $H(X)$ 。

? 为什么无失真离散信源编码的极限码率是 $H(X)$ ，而不是 $\log n$?

■ 9 信息率失真函数 $R(D)$

□□□□ 这一节把互信息变成压缩极限：如果允许一点失真，最少需要保留多少信息？

有失真信源编码的核心问题是：在允许平均失真不超过 D 的条件下，寻找最优的试验信道 $p(\hat{x}|x)$ ，使得互信息 $I(X; \hat{X})$ 最小。这个最小值就是 $R(D)$ 。

从无失真到允许失真

Trigger. 当题目不再要求 $\hat{X} = X$ ，而是给出一个“平均误差不超过 D ”时，就进入率失真框架。

在数字通信系统中，信源编码器与译码器的整体作用可以抽象为

$$X \xrightarrow{\text{编码/译码}} \hat{X}.$$

无失真编码要求 $\hat{X} = X$ ；有失真编码只要求二者之间的 平均失真 不超过某个允许值 D 。

Definition 9.1 (有失真编码的目标). 设信源 X 的字母表为 $\mathcal{X} = \{x_1, x_2, \dots, x_n\}$ ，重构符号字母表为 $\hat{\mathcal{X}} = \{\hat{x}_1, \hat{x}_2, \dots, \hat{x}_m\}$ 。有失真信源编码的目标是：在

$$\mathbb{E}[d(X, \hat{X})] \leq \underline{D}$$

的条件下，使编码所需的信息率尽可能 小。

失真测度

Definition 9.2 (失真测度). 失真测度是一个非负函数

$$d : \mathcal{X} \times \hat{\mathcal{X}} \rightarrow \mathbb{R}^+,$$

其中 $d(x_i, \hat{x}_j)$ 表示把 x_i 重构为 $\hat{x}_j$ 所产生的失真程度。通常要求

$$d(x_i, \hat{x}_j) \geq 0, \quad d(x_i, x_i) = \underline{0}.$$

Example 9.3 (汉明失真). 对于离散信源, 汉明失真只关心“对”或“错”:

$$d(x_i, \hat{x}_j) = \begin{cases} 0, & i = j, \\ 1, & i \neq j. \end{cases}$$

它的含义是: 译码正确时失真为零, 任何错误都计为同样大小的失真。

Example 9.4 (平方误差失真). 对于连续信源, 常用的失真测度是

$$d(x, \hat{x}) = \frac{(x - \hat{x})^2}{2}.$$

若 $X, \hat{X}$ 为向量, 则可推广为欧氏距离平方 $\|\mathbf{x} - \hat{\mathbf{x}}\|^2$ 。

Your turn. 汉明失真和平方误差失真的侧重点有何不同?

汉明失真: d 只与 是否相同 有关。

平方误差失真: d 还与 误差大小 有关。

平均失真与允许失真度

设信源分布为 $p(x_i)$, 试验信道为 $p(\hat{x}_j|x_i)$, 则联合分布为

$$p(x_i, \hat{x}_j) = p(x_i)p(\hat{x}_j|x_i).$$

Definition 9.5 (平均失真). 平均失真定义为

$$\bar{d} = \sum_{i=1}^n \sum_{j=1}^m p(x_i, \hat{x}_j) d(x_i, \hat{x}_j) = \mathbb{E}[d(X, \hat{X})].$$

Definition 9.6 (允许失真度). 允许失真度 D 是平均失真的上界。一个试验信道可行, 当且仅当

$$\bar{d} = \sum_{i=1}^n \sum_{j=1}^m p(x_i)p(\hat{x}_j|x_i) d(x_i, \hat{x}_j) \leq D.$$

Your turn. 当 D 变小时, 对重构质量的要求变 高, 因此所需信息率通常会变 大; 当 D 变大时, 信息率可以变 小。

试验信道

Definition 9.7 (试验信道). 在率失真理论中, 信源编码与译码的整体过程抽象为条件概率分布 $p(\hat{x}_j|x_i)$, 称为 试验信道。它不是一个物理信道, 而是描述编码/译码造成的随机映射。

所有满足平均失真约束的试验信道构成集合

$$\mathcal{P}_D = \{p(\hat{x}|x) : \mathbb{E}[d(X, \hat{X})] \leq D\}.$$

也就是说, $p(\hat{x}|x) \in \mathcal{P}_D$ 当且仅当

$$\sum_{i=1}^n \sum_{j=1}^m p(x_i)p(\hat{x}_j|x_i)d(x_i, \hat{x}_j) \leq D.$$

互信息作为“必须保留的信息量”

Proposition 9.8 (互信息的概率形式). 原信源 X 与重构信源 $\hat{X}$ 之间的互信息为

$$I(X; \hat{X}) = \sum_{i=1}^n \sum_{j=1}^m p(x_i)p(\hat{x}_j|x_i) \log \frac{p(\hat{x}_j|x_i)}{p(\hat{x}_j)},$$

其中

$$p(\hat{x}_j) = \sum_{i=1}^n p(x_i)p(\hat{x}_j|x_i).$$

互信息衡量: 重构信源 $\hat{X}$ 中保留了多少关于原信源 X 的信息。在有失真压缩中, $I(X; \hat{X})$ 越小, 意味着需要保留的信息越少, 相应编码所需的信息率越 低。

信息率失真函数的定义

Definition 9.9 (信息率失真函数). 信息率失真函数定义为

$$R(D) = \min_{p(\hat{x}|x) \in \mathcal{P}_D} I(X; \hat{X}).$$

展开写即

$$R(D) = \min_{p(\hat{x}|x)} I(X; \hat{X})$$

满足约束

$$\sum_{i=1}^n \sum_{j=1}^m p(x_i)p(\hat{x}_j|x_i)d(x_i, \hat{x}_j) \leq D,$$

$$\sum_{j=1}^m p(\hat{x}_j|x_i) = 1, \quad i = 1, 2, \dots, n,$$

$$p(\hat{x}_j|x_i) \geq 0, \quad i = 1, 2, \dots, n, j = 1, 2, \dots, m.$$

$R(D)$ 的含义是: 在平均失真不超过 D 的条件下, 编码所需的最小信息率。它是一个 带约束的优化问题, 优化变量是试验信道 $p(\hat{x}|x)$, 目标函数是互信息。

率失真函数的基本性质

Proposition 9.10 (非负性). 由于互信息非负, $I(X; \hat{X}) \geq 0$, 所以

$$R(D) \geq \underline{0}.$$

Proposition 9.11 (单调非增性). 若 $D_1 < D_2$, 则

$$R(D_1) \underline{\geq} R(D_2).$$

直观含义: 允许的失真越大, 可选的试验信道越多, 所需的最小信息率不会增加。

Proposition 9.12 (凸性). 率失真函数 $R(D)$ 是关于 D 的凸函数, 即对 $0 \leq \lambda \leq 1$, 有

$$R(\lambda D_1 + (1 - \lambda) D_2) \leq \lambda R(D_1) + (1 - \lambda) R(D_2).$$

Proof. 设两个最优试验信道分别达到 $(D_1, R(D_1))$ 和 $(D_2, R(D_2))$ 。以概率 λ 使用第一个信道、以概率 $1 - \lambda$ 使用第二个信道, 得到一个新的试验信道。其平均失真为

$$\lambda D_1 + (1 - \lambda) D_2,$$

而其互信息为

$$\lambda I(X; \hat{X}_1) + (1 - \lambda) I(X; \hat{X}_2) = \lambda R(D_1) + (1 - \lambda) R(D_2).$$

由于 $R(D)$ 是所有可行信道中互信息的最小值, 因此

$$R(\lambda D_1 + (1 - \lambda) D_2) \leq \lambda R(D_1) + (1 - \lambda) R(D_2).$$

Your turn. 凸性的关键动作是: 用 时间共享 把两个编码方案组合起来。新方案的失真和互信息分别是两个方案对应量的 加权平均, 因此率失真函数的图像不会“向上弯”。

Proposition 9.13 (连续性). 在通常条件下, $R(D)$ 是关于 D 的连续函数。

两个特殊点

Proposition 9.14 (零失真点). 当 $D = 0$ 时, 有失真编码退化为无失真编码。对于离散信源, 若失真测度满足

$$d(x_i, \hat{x}_j) = 0 \iff x_i = \hat{x}_j,$$

则零失真时必须要有 $\hat{X} = X$, 因此

$$R(0) = I(X; X) = \underline{H(X)}.$$

对于连续信源，要求完全无失真通常需要无限精度，因此

$$R(0) \rightarrow \underline{\infty}.$$

Proposition 9.15 (最大允许失真). 存在一个阈值 $D_{\max}$ ，使得当 $D \geq D_{\max}$ 时，可以不传输任何关于 X 的信息，而在接收端固定输出某个重构符号 $\hat{x}$ 。此时 X 与 $\hat{X}$ 独立， $I(X; \hat{X}) = \underline{0}$ ，故

$$R(D) = 0, \quad D \geq D_{\max}.$$

其中

$$D_{\max} = \min_{\hat{x} \in \hat{\mathcal{X}}} \sum_{i=1}^n p(x_i) d(x_i, \hat{x}).$$

Your turn. 补全 $D_{\max}$ 的直观含义：在 不发送信息 的情况下，接收端固定选择一个最优重构符号，所能达到的平均失真为 最小。

率失真曲线的整体图像

综合以上性质， $R(D)$ 的典型形状满足：

$$R(0) = H(X), \quad R(D) \text{ 单调非增且凸}, \quad R(D) = 0 \ (D \geq D_{\max}).$$

它刻画了 压缩率 与 重构质量 之间的最优折中。

Your turn. 用一句话概括 $R(D)$ 回答的问题：

若允许平均失真不超过 D ，最少需要保留多少 比特 来描述信源？

本节小结

概念	作用
失真测度 $d(x, \hat{x})$	刻画原符号与重构符号之间的差异。
平均失真 $\bar{d} = \mathbb{E}[d(X, \hat{X})]$	描述整体重构误差。
允许失真度 D	平均失真的上界。
试验信道 $p(\hat{x} x)$	描述编码/译码整体造成的随机映射。
率失真函数 $R(D)$	在失真约束下，编码所需的最小信息率。

为什么 $R(D)$ 关于 D 是单调非增的？
可以从集合论的角度，结合具体信源的 $R(D)$ 计算，例如二元对称信源在汉明失真下的率失真函数。